1η Υποχρεωτική Εργασία
Στο Μάθημα "Υπολογιστική Νοημοσύνη - Στατιστική Μάθηση"

Όνοματεπώνυμο: Γεώργιος Κεσογλίδης
ΑΕΜ: 220

7 Δεκεμβρίου 2025

Περίληψη

Στην παρούσα εργασία υλοποιήθηκε από το μηδέν ένας αλγόριθμος Support Vector Regression (SVR) με χρήση της μεθόδου Stochastic Gradient Descent. Το μοντέλο (MySVR) συγκρίθηκε με καθιερωμένους αλγόριθμους μηχανικής μάθησης (Random Forest, Ridge, Scikit-Learn SVR) σε δύο διαφορετικά σύνολα δεδομένων: California Housing και Diabetes. Η αξιολόγηση βασίστηκε σε μετρικές σφάλματος (RMSE, MAE) και στο συντελεστή προσδιορισμού (R^2).

Περιεχόμενα

1 Εισαγωγή **2**

2 Μεθοδολογία και Υλοποίηση **2**
2.1 Συνάρτηση Απώλειας (Epsilon Insensitive Loss) 2
2.2 Αρχιτεκτονική Δικτύου (Dense Layer) 2
2.3 Βελτιστοποιητής (SGD with Weight Decay) 2

3 Πειραματική Διαδικασία **2**
3.1 Προετοιμασία Δεδομένων 2
3.2 Μοντέλα Σύγκρισης 3

4 Αποτελέσματα **3**
4.1 California Housing Dataset 3
4.2 Diabetes Dataset 4

5 Συμπεράσματα **4**

1 Εισαγωγή

Η Παλινδρόμηση Διανυσμάτων Υποστήριξης (Support Vector Regression - SVR) είναι μια ισχυρή μέθοδος επιβλεπόμενης μάθησης που στοχεύει στην εύρεση μιας συνάρτησης $f(x)$ η οποία αποκλίνει από τους πραγματικούς στόχους y_i το πολύ κατά ϵ, ενώ παράλληλα παραμένει όσο το δυνατόν πιο ¨επίπεδη¨.

Σε αυτή την εργασία, υλοποιήσαμε μια προσαρμοσμένη εκδοχή του SVR (MySVR) χρησιμοποιώντας ένα νευρωνικό δίκτυο ενός επιπέδου (Dense Layer) και βελτιστοποίηση μέσω Stochastic Gradient Descent (SGD).

2 Μεθοδολογία και Υλοποίηση

Η υλοποίηση πραγματοποιήθηκε σε Python 3.12.4 σε περιβάλλον Jupyter Notebook.

2.1 Συνάρτηση Απώλειας (Epsilon Insensitive Loss)

Για την εκπαίδευση του SVR χρησιμοποιήθηκε η συνάρτηση απώλειας Epsilon-Insensitive, η οποία αγνοεί σφάλματα μικρότερα από ένα κατώφλι ϵ:

$$L_\epsilon(y, \hat{y}) = \max(0, |y - \hat{y}| - \epsilon) \tag{1}$$

Η παράγωγος αυτής της συνάρτησης, η οποία είναι απαραίτητη για τον αλγόριθμο SGD, ορίζεται ως:

$$\frac{\partial L}{\partial \hat{y}} = \begin{cases} -1 & \text{αν } y - \hat{y} > \epsilon \\ 1 & \text{αν } y - \hat{y} < -\epsilon \\ 0 & \text{διαφορετικά} \end{cases}$$

2.2 Αρχιτεκτονική Δικτύου (Dense Layer)

Η κλάση Dense υλοποιεί ένα πλήρως συνδεδεμένο επίπεδο.

- **Forward Pass**: Υπολογίζει την έξοδο $\hat{y} = XW + b$.
- **Backward Pass**: Υπολογίζει τις κλίσεις (gradients) για τα βάρη W και την πόλωση b χρησιμοποιώντας τον κανόνα της αλυσίδας.

2.3 Βελτιστοποιητής (SGD with Weight Decay)

Για την ενημέρωση των βαρών χρησιμοποιήθηκε ο Stochastic Gradient Descent με προσθήκη L2 Regularization (μείωση βαρών - weight decay) για την αποφυγή υπερπροσαρμογής (overfitting). Ο κανόνας ενημέρωσης είναι:

$$W_{t+1} = W_t \cdot (1 - \eta\lambda) - \eta \nabla L \tag{2}$$

όπου η ο ρυθμός μάθησης και λ η παράμετρος weight decay.

3 Πειραματική Διαδικασία

3.1 Προετοιμασία Δεδομένων

Χρησιμοποιήθηκαν δύο σύνολα δεδομένων από τη βιβλιοθήκη scikit-learn: 1. **California Housing**: Πρόβλεψη αξίας κατοικιών (20,640 δείγματα, 8 χαρακτηριστικά). 2. **Diabetes**: Πρόβλεψη εξέλιξης της νόσου (442 δείγματα, 10 χαρακτηριστικά).

Εφαρμόστηκε η εξής στρατηγική προεπεξεργασίας:

- **Διαχωρισμός**: 60% Εκπαίδευση, 40% Έλεγχος.
- **Κανονικοποίηση (Scaling)**: Εφαρμόστηκε StandardScaler ($z = \frac{x-\mu}{\sigma}$) τόσο στα χαρακτηριστικά εισόδου X όσο και στον στόχο y. Αυτό είναι κρίσιμο για τη σύγκλιση του ΣΫΡ.

3.2 Μοντέλα Σύγκρισης

Το MySVR συγκρίθηκε με τα εξής μοντέλα:

- SVR (Linear & RBF Kernel) της scikit-learn
- Ridge Regression (Γραμμικό μοντέλο με L2 ομαλοποίηση)
- Random Forest Regressor (Μη γραμμικό μοντέλο συνόλου)

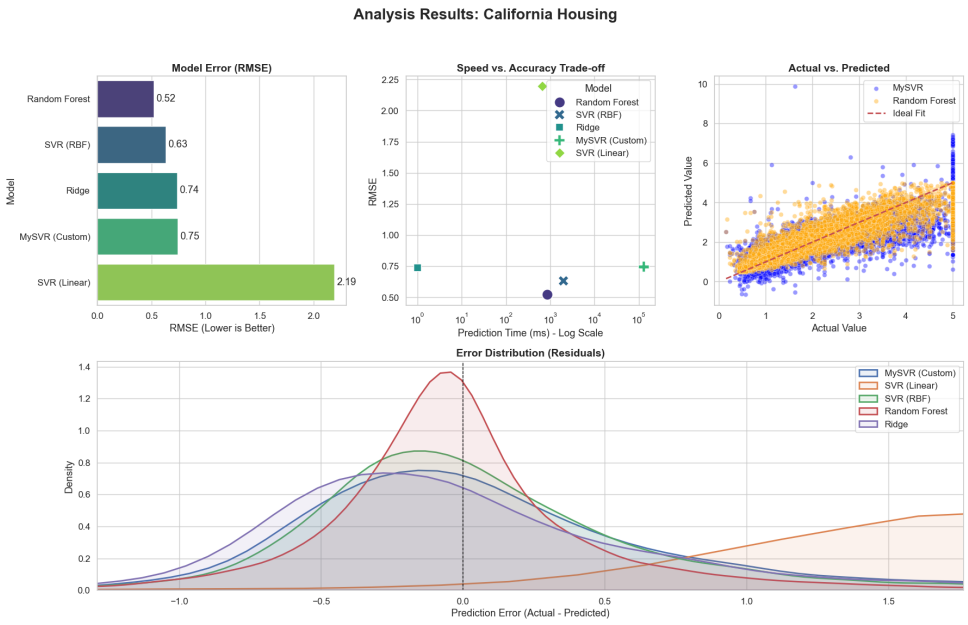
4 Αποτελέσματα

4.1 California Housing Dataset

Στον Πίνακα 1 παρουσιάζονται τα αποτελέσματα για το σύνολο δεδομένων California Housing. Το Random Forest πέτυχε την καλύτερη επίδοση, αναδεικνύοντας τη μη γραμμική φύση του προβλήματος. Το MySVR (το οποίο είναι γραμμικό στην τρέχουσα υλοποίηση) είχε παρόμοια επίδοση με το Ridge Regression.

Πίνακας 1: Αποτελέσματα στο California Housing

Μοντέλο	**RMSE**	**MAE**	R^2 **Score**	**Χρόνος (ms)**
Random Forest	0.5216	0.3428	0.7967	864
SVR (RBF)	0.6325	0.4484	0.7012	1986
Ridge	0.7373	0.5337	0.5940	1
MySVR (Custom)	**0.7457**	**0.5211**	**0.5847**	**129386**
SVR (Linear)	2.1943	1.9346	-2.5967	668



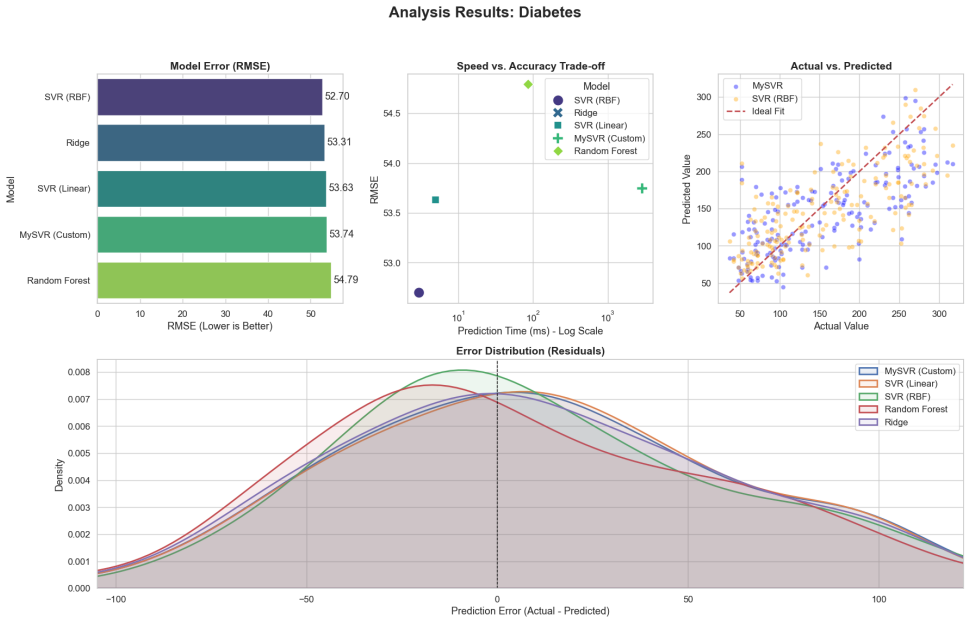
Σχήμα 1: Γραφική απεικόνιση αποτελεσμάτων για το California Housing. (α) Σύγκριση RMSE, (β) Πραγματικές ς Προβλεπόμενες τιμές.

4.2 Diabetes Dataset

Στον Πίνακα 2 βλέπουμε τα αποτελέσματα για το σύνολο δεδομένων Διαβετες. Εδώ, το πρόβλημα είναι πιο γραμμικό. Το MySVR πέτυχε επίδοση (RMSE: 53.74) εξαιρετικά κοντά στο SVR Linear της βιβλιοθήκης (RMSE: 53.63) και στο Ridge (RMSE: 53.31), αποδεικνύοντας την ορθότητα της υλοποίησης.

Πίνακας 2: Αποτελέσματα στο Diabetes

Μοντέλο	**RMSE**	**MAE**	R^2 **Score**	**Χρόνος (ms)**
SVR (RBF)	52.6987	40.9211	0.5253	3
Ridge	53.3114	42.5680	0.5142	0
SVR (Linear)	53.6305	42.6496	0.5084	5
MySVR (Custom)	**53.7446**	**42.7115**	**0.5063**	**2871**
Random Forest	54.7900	43.6450	0.4869	86



Σχήμα 2: Γραφική απεικόνιση αποτελεσμάτων για το Diabetes. (α) Σύγκριση RMSE, (β) Πραγματικές ς Προβλεπόμενες τιμές.

5 Συμπεράσματα

Η υλοποίηση του MySVR ήταν επιτυχής καθώς κατάφερε να προσεγγίσει την απόδοση των βελτιστοποιημένων βιβλιοθηκών σε γραμμικά προβλήματα (όπως το Diabetes).

- Η κανονικοποίηση του στόχου (y) αποδείχθηκε καθοριστική για τη σύγκλιση του αλγόριθμου.
- Ο χρόνος εκτέλεσης της Python υλοποίησης (MySVR) είναι σημαντικά μεγαλύτερος από τις C-optimized υλοποιήσεις του scikit-learn, κάτι που είναι αναμενόμενο.
- Σε μη γραμμικά δεδομένα (California Housing), το RBF kernel και τα Random Forests υπερέχουν ξεκάθαρα έναντι των γραμμικών προσεγγίσεων.